

Informe_Tecnico_Reto4_jdthg

- [Informe Técnico - Reto 4: Data Mining Aplicado a Pobreza Infantil](#)
 - [1. Contexto y Objetivo](#)
 - [2. Selección del Dataset](#)
 - [3. Técnicas Aplicadas](#)
 - [4. Evaluación Comparativa de Modelos](#)
 - [5. Interpretación de Resultados](#)
 - [6. Limitaciones del Análisis](#)
 - [7. Conclusiones](#)
 - [8. Anexos](#)

Informe Técnico - Reto 4: Data Mining Aplicado a Pobreza Infantil

Analista: jdthg **Fecha:** 2026-09-17 **Módulo:** BI y Big Data - Nivel 5 **Reto:** Aplicación de Técnicas Avanzadas de Data Mining

1. Contexto y Objetivo

Contexto Narrativo

El viajero llega al Santuario de los Secretos Ocultos, donde debe descifrar patrones y asociaciones en un vasto conjunto de datos sobre pobreza infantil.

Objetivo del Análisis

Aplicar técnicas avanzadas de Data Mining (clasificación, clustering y asociación) para extraer insights que informen políticas de reducción de pobreza infantil.

2. Selección del Dataset

Fuente

Repositorio: world-bank-unicef-data (GitHub - danribes) **Archivo:** world_bank_gdp_data_with_poverty.xlsx
Origen: Banco Mundial + UNICEF

Características

- **14.105 registros** (país × año)
- **217 países**
- **64 columnas**

- **Periodo:** 1960-2024
- **Variables:** económicas, fiscales, pobreza, mortalidad infantil, nutrición, desigualdad

Justificación de la Elección

1. **Volumen suficiente** para algoritmos avanzados
2. **Variables mixtas** (numéricas + categóricas)
3. **Relevancia de negocio** directa: pobreza infantil
4. **Fuentes oficiales** con documentación clara
5. **Cobertura temporal** amplia (64 años)

Preparación

- Filtrado a partir del año 2000 (mayor calidad de datos)
- Selección de 21 columnas relevantes
- Dos datasets derivados: clasificación (4.577 filas) y clustering (1.833 filas)

3. Técnicas Aplicadas

3.1 CLASIFICACIÓN

Objetivo: Predecir si un país tiene alta mortalidad infantil (> mediana 19.84)

Variables objetivo: `high_child_mortality` (binaria, balance 50/50)

Modelos evaluados:

Modelo	Accuracy	Precision	Recall	F1-Score	ROC-AUC
RandomForest	0.9309	0.9405	0.9199	0.9301	0.9812
SVM	0.8624	0.8487	0.8821	0.8651	0.9487
DecisionTree	0.8523	0.8184	0.9054	0.8597	0.9460

Modelo ganador: RandomForest

Top 5 features más importantes: 1. `gdp_per_capita_current_usd` (44.9%) 2. `low_birth_weight_pct` (10.6%) 3. `poverty_headcount_8_dollars_pct` (9.6%) 4. `poverty_headcount_4_dollars_pct` (7.2%) 5. `gdp_billions_usd` (6.9%)

Visualizaciones: - `clasificacion_comparativa.png` - `clasificacion_matriz_confusion.png` - `clasificacion_roc.png` - `clasificacion_arbol.png` - `clasificacion_importancia.png`

3.2 CLUSTERING

Objetivo: Segmentar países por perfil de pobreza

Variables: GDP, Gini, mortalidad <5, pobreza <3 USD

Algoritmos evaluados:

Algoritmo	Silueta	Davies-Bouldin	Calinski-Harabasz	Clusters
K-means	0.5370	0.8997	1605.52	2
DBSCAN	0.5602	0.5971	304.31	3
Jerarquico	0.5615	0.7822	1371.60	2

Algoritmo ganador: K-means con K=2

Perfiles de clusters:

Cluster	Países	GDP	Gini	Mortalidad	Pobreza
0	1.504	\$21.820	35.1	10.8	2.8%
1	329	\$1.569	43.2	68.2	39.5%

Visualizaciones: - clustering_k_optimo.png - clustering_pca_comparativa.png - clustering_dendrograma.png - clustering_boxplots.png

3.3 ASOCIACIÓN

Objetivo: Descubrir reglas entre indicadores

Algoritmos: Apriori y FP-Growth (mismo resultado: 75 itemsets)

Parámetros: soporte $\geq$ 5%, confianza $\geq$ 60%, lift $>$ 1.1

Total reglas: 85

Top 5 reglas por lift:

Antecedentes	Consecuente	Soporte	Confianza	Lift
Pob_Alta, GDP_Bajo	frozenset({'Mort_Alta'})	0.0797	0.6952	6.37
Mort_Alta	frozenset({'Pob_Alta', 'GDP_Bajo'})	0.0797	0.7300	6.37
Mort_Alta	frozenset({'Pob_Alta'})	0.0955	0.8750	5.69
Pob_Alta	frozenset({'Mort_Alta'})	0.0955	0.6206	5.69
GDP_Bajo, Mort_Alta	frozenset({'Pob_Alta'})	0.0797	0.8639	5.62

Regla estrella: GDP_Bajo + Pob_Alta $\rightarrow$ Mort_Alta con lift=6.37

Visualizaciones: - asociacion_scatter.png - asociacion_heatmap.png - asociacion_top10.png - asociacion_red.png

4. Evaluación Comparativa de Modelos

Criterios de selección:

Criterio	Clasificación	Clustering	Asociación
Métrica principal	F1-Score	Silueta	Lift
Modelo elegido	Random Forest	K-means (K=2)	FP-Growth
Valor obtenido	0.9301	0.5370	6.37
Interpretabilidad	Media (importancia features)	Alta (perfiles claros)	Alta (reglas legibles)
Aplicabilidad	Alta	Alta	Muy alta

5. Interpretación de Resultados

Insight #1: El PIB es el predictor dominante

El GDP per cápita explica el 44.9% de la capacidad predictiva del modelo. **Implicación:** Las intervenciones económicas tienen el mayor potencial de impacto.

Insight #2: Existen dos mundos separados

Los 217 países se dividen claramente en: - **82%** con desarrollo relativo (mortalidad <11) - **18%** en situación crítica (mortalidad >68)

Implicación: Políticas diferenciadas por segmento.

Insight #3: La trampa de la pobreza es real

La regla `GDP_Bajo + Pob_Alta → Mort_Alta` con lift 6.37 demuestra que los factores se refuerzan mutuamente.

Implicación: Se requieren intervenciones multidimensionales.

6. Limitaciones del Análisis

- Datos faltantes:** Algunas variables clave tienen <20% de cobertura
- Sesgo temporal:** 2024 tiene datos incompletos
- Correlación ≠ causalidad:** Los hallazgos son asociativos
- Variables omitidas:** No se incluyen factores políticos, culturales o geográficos
- Deriva del modelo:** Requiere reentrenamiento anual

7. Conclusiones

El análisis demuestra que las **técnicas avanzadas de Data Mining** permiten:

1. **Predecir** con alta precisión ($F1=0.93$) qué países tienen riesgo de mortalidad infantil alta
2. **Segmentar** países en grupos homogéneos para políticas diferenciadas
3. **Descubrir** reglas de asociación que revelan la interacción entre factores
4. **Priorizar** recursos basándose en datos objetivos

El hallazgo más relevante para el negocio es que **la combinación de pobreza extrema y bajo desarrollo económico eleva 6.4x el riesgo de mortalidad infantil**, lo cual justifica un enfoque integrado de intervenciones.

8. Anexos

Código fuente

- `src/01_exploracion.py` - Exploración inicial
- `src/02_diagnostico.py` - Diagnóstico de calidad
- `src/03_preparacion.py` - Limpieza y preparación
- `src/04_clasificacion.py` - Clasificación
- `src/05_clustering.py` - Clustering
- `src/06_asociacion.py` - Asociación
- `src/06b_visualizaciones_asociacion.py` - Visualizaciones adicionales
- `src/07_evaluacion_interpretacion.py` - Evaluación
- `src/08_recomendaciones.py` - Recomendaciones

Modelos entrenados

- `models/mejor_modelo_clasificacion.pkl`
- `models/kmeans_clustering.pkl`
- `models/reglas_asociacion.pkl`

Datos procesados

- `data/processed/df_clasificacion.csv`
- `data/processed/df_clustering.csv`
- `data/processed/paises_con_cluster.csv`
- `data/processed/perfiles_clusters.csv`
- `data/processed/reglas_asociacion.csv`
- `data/processed/resultados_completos.xlsx`

Figuras (15)

Todas en `reports/figures/`

Fin del informe técnico